

APRENDIZAJE DE MÁQUINAS (ACIF104) **INFORME FASE 2**

Alumnos : Priscila Arganaraz
Carlos González

Profesor : Omar Salinas

Curso : ACIF104.202605.2182.EL.ON

Fecha : 14 de abril de 2026

INDICE

I.	PORTADA	
II.	INDICE	02
III.	PROBLEMÁTICA	03
IV.	METODOLOGÍA	04
V.	DESARROLLO DEL PROYECTO	05
	a. ANÁLISIS EXPLORATORIO DE DATOS	05
	b. SELECCIÓN DE TÉCNICAS	06
	c. COMPARACIÓN DE TÉCNICAS	07
	d. REQUISITOS DEL PROYECTO	10
	e. SELECCIÓN DE LA ARQUITECTURA	11
	f. ELABORACIÓN DE MODELOS	12
	g. DESARROLLO FRONTEND Y BACKEND	15
VI.	RESULTADOS	16
VII.	PROPUESTA DE MEJORAS	17
VIII.	CÓDIGO DE FUENTE EN GITHUB (ANEXO LINK)	18
IX.	BIBLIOGRAFÍA	19

III. PROBLEMÁTICA

El accidente cerebrovascular (stroke) constituye una de las principales causas de muerte y discapacidad a nivel mundial, generando un alto impacto tanto en los sistemas de salud como en la calidad de vida de las personas. La detección temprana de factores de riesgo resulta fundamental para reducir la incidencia de esta enfermedad y mejorar las estrategias de prevención.

En este contexto, el presente proyecto aborda la problemática de predecir la ocurrencia de accidentes cerebrovasculares mediante el uso de técnicas de Machine Learning, utilizando variables demográficas y clínicas de pacientes.

La relevancia de este problema radica en la posibilidad de apoyar la toma de decisiones médicas mediante modelos predictivos, permitiendo identificar individuos con alto riesgo y facilitar intervenciones preventivas oportunas.

Para el desarrollo de este proyecto, se establecen como requisitos iniciales la utilización de un dataset estructurado, la correcta identificación de la variable objetivo (stroke), el aseguramiento de la calidad de los datos mediante procesos de limpieza y la implementación de modelos capaces de generar predicciones confiables.

Adicionalmente, se considera como un desafío relevante el desbalance de clases presente en el dataset, lo que implica la necesidad de aplicar técnicas específicas que permitan mejorar la capacidad del modelo para detectar correctamente los casos positivos.

Este enfoque permite abordar una problemática de alta relevancia en el ámbito de la salud, integrando herramientas tecnológicas avanzadas para la generación de conocimiento predictivo.

IV. METODOLOGÍA

Para el desarrollo del presente proyecto se utilizó una metodología estructurada basada en las etapas del proceso de aprendizaje de máquinas revisadas en clases, permitiendo abordar el problema de forma ordenada y sistemática.

Las fases consideradas fueron las siguientes:

1. Carga de datos: se realizó la importación del dataset correspondiente a información clínica y demográfica de pacientes.
2. Análisis exploratorio de datos: se examinó la estructura del dataset, identificando tipos de variables, distribución de datos y presencia de valores faltantes.
3. Limpieza de datos: se corrigieron inconsistencias detectadas, especialmente en la variable "bmi", donde se imputaron valores faltantes utilizando el promedio.
4. Transformación de datos: se prepararon las variables para el modelamiento, aplicando técnicas como One-Hot Encoding en variables categóricas.
5. Modelado: se implementó un modelo de clasificación basado en Random Forest para la predicción de la variable objetivo.
6. Evaluación: se analizaron los resultados mediante métricas como accuracy, precision, recall y f1-score, identificando limitaciones del modelo.
7. Mejora del modelo: se aplicaron técnicas de balanceo de clases, específicamente SMOTE, con el objetivo de mejorar la detección de la clase minoritaria.

Es importante destacar que, siguiendo las indicaciones del profesor, se priorizó la limpieza de los datos antes de realizar cualquier tipo de análisis o visualización, evitando trabajar con información incompleta o errónea.

Finalmente, la metodología adoptada permitió desarrollar un flujo de trabajo coherente, facilitando la interpretación de resultados y la toma de decisiones en cada etapa del proyecto.

Esta metodología se alinea con enfoques como CRISP-DM, ampliamente utilizados en proyectos de ciencia de datos.

V. DESARROLLO DEL PROYECTO

En esta sección se presenta el desarrollo del proyecto de Machine Learning, abordando de manera estructurada cada una de las etapas necesarias para la construcción del modelo predictivo.

Se describen desde el análisis inicial de los datos hasta la implementación del modelo, incluyendo la selección de técnicas, definición de requisitos, arquitectura del sistema y desarrollo de la solución.

Cada etapa se desarrolla considerando las buenas prácticas revisadas en clases, asegurando la calidad del proceso y la correcta interpretación de los resultados obtenidos.

a. ANALISIS EXPLORATORIO DE DATOS

En esta etapa se realizó un análisis exploratorio del dataset con el objetivo de comprender su estructura, identificar el tipo de variables y evaluar la calidad de los datos disponibles.

El dataset contiene información demográfica y clínica de pacientes, incluyendo variables como edad, nivel de glucosa, índice de masa corporal (bmi), estado civil, tipo de trabajo, tipo de residencia y hábitos de tabaquismo.

Se llevó a cabo una revisión de los valores nulos presentes en el dataset, identificándose que la mayoría de las variables no presentan datos faltantes. Sin embargo, la variable "bmi" presenta valores nulos, lo que representa un aspecto relevante a considerar en el proceso de limpieza de datos.

Adicionalmente, se clasificaron las variables en numéricas y categóricas, permitiendo definir el tratamiento adecuado en las etapas posteriores del análisis.

Este análisis inicial permitió detectar posibles problemas en la calidad de los datos y establecer una base sólida para el desarrollo del modelo.

```
import pandas as pd

# Cargar dataset
df = pd.read_csv('healthcare-dataset-stroke-data.csv')

# Ver primeras filas
df.head()
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	1665	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Figura 1: Muestra del dataset utilizada para el análisis exploratorio inicial.




Figura 2: Identificación de valores nulos en el dataset.

El análisis exploratorio permitió comprender en profundidad la estructura del dataset, identificando las características principales de las variables y detectando posibles problemas en la calidad de los datos. En particular, la presencia de valores nulos en la variable "bmi" evidenció la necesidad de aplicar técnicas de limpieza adecuadas antes de avanzar hacia etapas de modelamiento.

Asimismo, esta etapa resultó fundamental para definir el tratamiento posterior de las variables, distinguiendo correctamente entre variables numéricas y categóricas. Esto permitió seleccionar técnicas apropiadas de transformación y modelado, asegurando la coherencia del proceso y contribuyendo a la obtención de resultados más confiables en las etapas siguientes del proyecto.

b. SELECCIÓN DE TECNICAS

Para el desarrollo del modelo predictivo se seleccionó el algoritmo Random Forest, el cual corresponde a una técnica de aprendizaje supervisado basada en un conjunto de árboles de decisión.

La elección de este algoritmo se fundamenta en su capacidad para manejar datos estructurados, su robustez frente a valores atípicos y su buen desempeño en problemas de clasificación. Además, Random Forest permite reducir el riesgo de sobreajuste al combinar múltiples modelos simples en uno más robusto.

En cuanto al preprocesamiento de los datos, se aplicó la técnica de One-Hot Encoding para la transformación de variables categóricas, permitiendo su correcta incorporación en el modelo sin asumir un orden jerárquico entre sus valores.

Adicionalmente, se consideró la aplicación de la técnica SMOTE (Synthetic Minority Over-sampling Technique), debido a la presencia de desbalance en la variable objetivo, con el fin de mejorar la capacidad del modelo para identificar correctamente la clase minoritaria.



Figura 3: Flujo de técnicas utilizadas en el modelo de Machine Learning.

La selección de estas técnicas responde a la necesidad de construir un modelo capaz de generalizar adecuadamente, considerando tanto la calidad de los datos como las características del problema. En particular, el uso de SMOTE se justifica como una estrategia para evitar que el modelo favorezca mayoritariamente la clase dominante, lo cual es un problema común en datasets desbalanceados.

De esta manera, la combinación de técnicas de preprocesamiento y modelado permitió establecer una base sólida para el desarrollo del modelo predictivo, asegurando coherencia metodológica y mejorando la interpretación de los resultados obtenidos.

c. COMPARACION DE TECNICAS

Durante el desarrollo del proyecto se realizó una comparación entre el modelo inicial y el modelo mejorado mediante técnicas de balanceo de datos.

En una primera instancia, se entrenó un modelo utilizando el dataset original, observándose un alto valor de accuracy. Sin embargo, al analizar el reporte de clasificación, se evidenció que el modelo no fue capaz de predecir correctamente la clase minoritaria (stroke), asignando la mayoría de los casos a la clase dominante.

Este comportamiento refleja un problema típico en datasets desbalanceados, donde el modelo tiende a favorecer la clase mayoritaria, generando una falsa percepción de buen desempeño si solo se considera la métrica de accuracy.

Posteriormente, se aplicó la técnica SMOTE con el objetivo de equilibrar la distribución de clases. Al entrenar nuevamente el modelo con los datos balanceados, se observó una mejora en la capacidad de detección de la clase minoritaria, especialmente en métricas como recall y f1-score.

Esta comparación permitió evidenciar la importancia de utilizar métricas adecuadas y técnicas de balanceo de datos en problemas de clasificación, asegurando una evaluación más completa y realista del desempeño del modelo.




Figura 4: Se observa que el modelo inicial presenta un alto valor de accuracy, sin embargo, no logra identificar correctamente la clase minoritaria (stroke), lo que evidencia un problema de desbalance de datos.




Figura 5: Se observa una mejora en la capacidad del modelo para detectar la clase minoritaria, lo cual se refleja en el aumento de métricas como recall y f1-score tras la aplicación de la técnica SMOTE.

Los resultados obtenidos evidencian una mejora significativa en la capacidad del modelo para identificar la clase minoritaria tras la aplicación de la técnica SMOTE. En particular, se observa un incremento en la métrica recall para la clase positiva, lo que indica una mayor efectividad en la detección de casos de riesgo, aspecto fundamental en un problema de salud como el abordado en este proyecto.

Por otra parte, el análisis del modelo inicial revela la presencia de advertencias en las métricas de evaluación, lo que confirma su bajo desempeño en la predicción de la clase minoritaria. Esto refuerza la importancia de aplicar técnicas de balanceo de datos, ya que un alto valor de accuracy por sí solo no garantiza un modelo adecuado cuando existe desbalance de clases.

En este contexto, la comparación entre ambos modelos permite concluir que la aplicación de técnicas adecuadas de preprocesamiento es clave para obtener resultados confiables y útiles en escenarios reales.

d. REQUISITOS DEL PROYECTO

Para el desarrollo del presente proyecto de Machine Learning, se definieron una serie de requisitos funcionales y no funcionales que permitieron asegurar la correcta implementación y evaluación del modelo predictivo.

En cuanto a los requisitos funcionales, el sistema debe ser capaz de procesar un dataset estructurado, realizar la limpieza de datos, transformar variables categóricas en variables numéricas, entrenar un modelo de clasificación y generar predicciones sobre la ocurrencia de accidentes cerebrovasculares (stroke). Asimismo, debe permitir evaluar el desempeño del modelo mediante métricas como accuracy, precision, recall y f1-score.

Por otra parte, dentro de los requisitos no funcionales, se considera la necesidad de que el modelo sea reproducible, interpretable y eficiente en términos computacionales. Además, se busca que el proceso de desarrollo esté correctamente documentado, permitiendo su comprensión y reutilización en futuros proyectos.

Adicionalmente, se estableció como requisito clave la correcta gestión del desbalance de clases presente en el dataset, incorporando técnicas como SMOTE para mejorar la capacidad predictiva del modelo sobre la clase minoritaria.

Finalmente, se consideró como requisito la integración del proyecto en un repositorio GitHub, facilitando el acceso al código fuente, la trazabilidad del desarrollo y la posibilidad de colaboración.



Figura 6: Repositorio GitHub del proyecto, donde se almacenan los archivos y código fuente.

e. SELECCIÓN DE LA ARQUITECTURA

Para el desarrollo del proyecto, se definió una arquitectura de tipo modular, diferenciando claramente las etapas de procesamiento de datos, modelado y presentación de resultados. Esta estructura permite una mejor organización del sistema, facilitando su mantenimiento, escalabilidad y comprensión.

En este contexto, el proyecto puede interpretarse bajo una lógica de separación entre backend y frontend. El backend está representado por todo el procesamiento realizado en el entorno de desarrollo (Google Colab), incluyendo la carga de datos, limpieza, transformación de variables, entrenamiento del modelo y generación de predicciones. Esta capa es responsable de la lógica principal del sistema y del funcionamiento del modelo de Machine Learning.

Por otro lado, el frontend corresponde a la presentación de los resultados, ya sea a través de reportes, visualizaciones o documentación del proyecto. En este caso, el frontend se materializa en el informe desarrollado en Word y en las visualizaciones generadas, permitiendo interpretar y comunicar los resultados obtenidos de manera clara, en coherencia con el alcance definido para esta etapa del trabajo.

Adicionalmente, se considera la integración con GitHub como un componente de la arquitectura, funcionando como repositorio central del proyecto. Este permite almacenar el código fuente, los datos y la documentación, facilitando la trazabilidad, el control de versiones y la colaboración.

Finalmente, la arquitectura adoptada permite separar responsabilidades dentro del sistema, lo que es una buena práctica en proyectos de desarrollo y análisis de datos, asegurando una mayor claridad y orden en cada una de las etapas del proceso.



Figura 7: Arquitectura del sistema, mostrando la separación entre backend (procesamiento y modelado) y frontend (visualización de resultados).

f. ELABORACION DE MODELOS

En esta etapa se llevó a cabo la construcción y entrenamiento de modelos de Machine Learning orientados a la predicción de accidentes cerebrovasculares (stroke), utilizando como base el dataset previamente procesado.

Como primer enfoque, se implementó un modelo de clasificación utilizando el algoritmo Random Forest, seleccionado por su capacidad para manejar variables numéricas y categóricas, así como por su robustez frente a datos ruidosos y su buen desempeño en problemas de clasificación. El modelo fue entrenado utilizando un conjunto de datos dividido en entrenamiento y prueba, permitiendo evaluar su capacidad de generalización.

Posteriormente, se identificó la presencia de un desbalance significativo entre las clases del dataset, lo que afectaba negativamente la capacidad del modelo para predecir la clase minoritaria. Frente a esta problemática, se incorporó la técnica de sobremuestreo SMOTE (Synthetic Minority Over-sampling Technique), con el objetivo de generar nuevas instancias sintéticas de la clase minoritaria y equilibrar la distribución de los datos.

A partir de esta mejora, se entrenó un segundo modelo basado en Random Forest utilizando los datos balanceados, permitiendo comparar su desempeño respecto al modelo inicial. Esta comparación evidenció una mejora en la capacidad del modelo para detectar casos positivos, particularmente en métricas como recall y f1-score.

Finalmente, el proceso de elaboración de modelos permitió validar la importancia del preprocesamiento de datos y la selección de técnicas adecuadas, demostrando que la calidad del modelo no depende únicamente del algoritmo utilizado, sino también de la correcta preparación de los datos.

```
from sklearn.ensemble import RandomForestClassifier

model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)

RandomForestClassifier
RandomForestClassifier(random_state=42)

y_pred = model.predict(X_test)
```

Figura 8: Entrenamiento del modelo Random Forest utilizando los datos procesados.

```
from sklearn.metrics import accuracy_score, classification_report

accuracy = accuracy_score(y_test, y_pred)
print("Accuracy:", accuracy)

print("\nReporte de clasificación:\n")
print(classification_report(y_test, y_pred))

Accuracy: 0.9393346379647749

Reporte de clasificación:
              precision    recall  f1-score   support

     0       0.94         1.00         0.97         960
     1       0.00         0.00         0.00          62

 accuracy          0.94         1022
 macro avg         0.47         0.50         0.48         1022
 weighted avg       0.88         0.94         0.91         1022

/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use 'zero_division' parameter to control.
_warn_prf(average, modifier, f'{metric.capitalize()} is', len(result))
/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use 'zero_division' parameter to control.
_warn_prf(average, modifier, f'{metric.capitalize()} is', len(result))
/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use 'zero_division' parameter to control.
_warn_prf(average, modifier, f'{metric.capitalize()} is', len(result))
```

Figura 9: Resultados del modelo Random Forest sin balanceo de clases. A pesar de presentar un alto valor de accuracy, el modelo no logra predecir correctamente la clase minoritaria, evidenciado por valores nulos en recall y f1-score para dicha clase.




Figura 10: Resultados del modelo Random Forest utilizando datos balanceados mediante la técnica SMOTE, evidenciando una mejora en la detección de la clase minoritaria.

A partir de la aplicación de la técnica SMOTE, se observa una mejora en el desempeño del modelo en la predicción de la clase minoritaria. En particular, el incremento en la métrica recall indica que el modelo logra identificar una mayor proporción de casos positivos, lo que resulta fundamental en un contexto de predicción de riesgos en salud.

Si bien los valores obtenidos aún pueden ser mejorados, el modelo demuestra un avance significativo respecto al modelo inicial, evidenciando la importancia de abordar el desbalance de clases en problemas de clasificación.

g. DESARROLLO FRONTEND Y BACKEND

En el desarrollo del presente proyecto se adoptó una estructura basada en la separación conceptual entre frontend y backend, permitiendo organizar de manera clara las distintas responsabilidades del sistema.

El backend corresponde a la capa donde se implementa la lógica principal del proyecto. En este caso, se desarrolló utilizando Python en el entorno Google Colab, abarcando procesos como la carga de datos, limpieza, transformación de variables, aplicación de técnicas de balanceo de clases (SMOTE), entrenamiento del modelo Random Forest y generación de predicciones. Esta capa es fundamental, ya que en ella se construye y ejecuta el modelo de Machine Learning.

Por otro lado, el frontend se enfoca en la presentación e interpretación de los resultados obtenidos. En este proyecto, el frontend se materializa a través del informe desarrollado en Word, donde se documenta el proceso completo, se presentan visualizaciones y se analizan los resultados. Esta capa permite traducir los datos y métricas técnicas en información comprensible para la toma de decisiones.

Adicionalmente, se incorpora el uso de GitHub como herramienta de integración, permitiendo gestionar el código fuente, almacenar los archivos del proyecto y facilitar su acceso. Esto aporta valor en términos de trazabilidad, control de versiones y organización del trabajo.

Finalmente, la separación entre frontend y backend permite estructurar el proyecto de manera más ordenada y profesional, alineándose con buenas prácticas de desarrollo de software y análisis de datos, y facilitando futuras mejoras o ampliaciones del sistema.




Figura 11: Representación del flujo del sistema, diferenciando las capas de backend (procesamiento y modelado) y frontend (presentación de resultados).

VI. RESULTADOS

En esta etapa se presentan los resultados obtenidos a partir de la implementación de los modelos de Machine Learning desarrollados en el proyecto, con el objetivo de evaluar su desempeño en la predicción de accidentes cerebrovasculares (stroke).

El modelo inicial basado en Random Forest, entrenado con los datos originales, presentó un alto valor de accuracy, cercano al 94%. Sin embargo, al analizar en detalle el reporte de clasificación, se evidenció que el modelo no lograba predecir correctamente la clase minoritaria, correspondiente a los casos positivos de stroke. Esto se reflejó en valores nulos de recall y f1-score para dicha clase, lo que indica una baja capacidad del modelo para detectar casos de riesgo.

Posteriormente, al aplicar la técnica de balanceo de datos SMOTE, se observó una mejora en el desempeño del modelo en relación con la clase minoritaria. En particular, el valor de recall aumentó, permitiendo identificar una mayor proporción de casos positivos. Esta mejora, si bien no alcanza niveles óptimos, representa un avance significativo respecto al modelo inicial.

Es importante destacar que, en problemas con desbalance de clases, métricas como el accuracy pueden resultar engañosas, ya que un modelo puede presentar un alto valor global, pero un bajo desempeño en la clase de interés. Por esta razón, el análisis de métricas como recall y f1-score resulta fundamental para evaluar correctamente la calidad del modelo.

En consecuencia, los resultados obtenidos permiten concluir que la incorporación de técnicas de preprocesamiento, como el balanceo de datos, tiene un impacto directo en la capacidad predictiva del modelo, especialmente en la detección de eventos poco frecuentes pero críticos, como los accidentes cerebrovasculares.

	precision	recall	f1-score	support
0	0.95	0.98	0.96	960
1	0.32	0.16	0.22	62
accuracy			0.93	1022
macro avg	0.64	0.57	0.59	1022
weighted avg	0.91	0.93	0.92	1022

Figura 12: Métricas de evaluación del modelo Random Forest con datos balanceados mediante SMOTE, donde se observa una mejora en la capacidad de detección de la clase minoritaria.

La figura evidencia un cambio cualitativo relevante en el comportamiento del modelo tras la aplicación de la técnica SMOTE. A diferencia del modelo inicial, que no lograba identificar ningún caso de la clase minoritaria (recall = 0.00), el modelo ajustado presenta un recall de 0.16 y un f1-score de 0.22 para la clase positiva. Si bien estos valores aún son moderados, representan un avance significativo, ya que el modelo

comienza a reconocer eventos asociados a la ocurrencia de accidentes cerebrovasculares.

Desde una perspectiva interpretativa, el valor de recall de 0.16 indica que el modelo es capaz de identificar aproximadamente un 16% de los casos positivos reales, lo que, aunque limitado, resulta considerablemente más útil que un modelo que no detecta ningún caso. Por su parte, el f1-score refleja un equilibrio entre precisión y sensibilidad, evidenciando que el modelo no solo detecta algunos casos, sino que comienza a hacerlo con cierta consistencia.

En este sentido, los resultados obtenidos permiten afirmar que la aplicación de técnicas de balanceo no solo mejora las métricas cuantitativas, sino que transforma el comportamiento del modelo hacia uno más alineado con el objetivo del problema. Así, el modelo pasa de ser técnicamente preciso pero poco útil, a convertirse en una herramienta con mayor valor predictivo y potencial aplicabilidad en escenarios reales, especialmente en contextos donde la detección temprana de riesgos es fundamental.

VII. PROPUESTAS DE MEJORAS

A partir de los resultados obtenidos en el desarrollo del proyecto, es posible identificar diversas oportunidades de mejora orientadas a optimizar el desempeño del modelo y aumentar su aplicabilidad en contextos reales.

En primer lugar, se propone la exploración de otros algoritmos de Machine Learning que podrían ofrecer mejores resultados en la detección de la clase minoritaria. Modelos como Gradient Boosting, XGBoost o redes neuronales podrían capturar relaciones más complejas entre las variables y mejorar las métricas de clasificación, especialmente en escenarios con datos desbalanceados.

En segundo lugar, se sugiere la optimización de los hiperparámetros del modelo Random Forest mediante técnicas como Grid Search o Random Search. Este proceso permitiría ajustar de manera más precisa el comportamiento del modelo, mejorando su capacidad predictiva y reduciendo posibles sesgos en la clasificación.

Adicionalmente, se recomienda profundizar en el tratamiento del desbalance de clases, combinando distintas estrategias como el uso de SMOTE junto con técnicas de submuestreo (undersampling) o el ajuste de pesos de clase (class_weight). Esto permitiría lograr un mejor equilibrio entre precisión y recall, optimizando la detección de casos positivos.

Otra línea de mejora relevante corresponde a la incorporación de nuevas variables o fuentes de datos que puedan enriquecer el modelo. Variables clínicas adicionales, historial médico o hábitos de vida podrían aportar información relevante para mejorar la capacidad predictiva del sistema.

Finalmente, desde una perspectiva de desarrollo, se propone la implementación de una interfaz interactiva (frontend) que permita ingresar datos y obtener predicciones en tiempo real, conectada a un backend que ejecute el modelo entrenado. Esto permitiría transformar el proyecto en una herramienta funcional, facilitando su uso en entornos prácticos.

En conclusión, si bien el modelo desarrollado cumple con el objetivo planteado, existen múltiples oportunidades para mejorar su desempeño y llevarlo a un nivel más avanzado, tanto desde el punto de vista técnico como de su aplicación en escenarios reales.

Estas mejoras propuestas evidencian que el desarrollo de modelos de Machine Learning es un proceso iterativo, donde la mejora continua es fundamental para alcanzar resultados robustos y confiables en el largo plazo.

VIII. CÓDIGO DE FUENTE EN GITHUB (ANEXO LINK)

El código fuente desarrollado para el presente proyecto se encuentra disponible en la plataforma GitHub, permitiendo su acceso, revisión y reproducción por parte de terceros.

El repositorio incluye el notebook de Google Colab con todo el proceso de análisis, limpieza de datos, transformación de variables, modelamiento y evaluación del modelo de Machine Learning. Asimismo, contiene el dataset utilizado y el archivo README.md, en el cual se describe la estructura del proyecto, los archivos incluidos y las instrucciones básicas para su ejecución.

El uso de GitHub como repositorio permite asegurar la trazabilidad del desarrollo, el control de versiones y la correcta organización de los archivos, alineándose con buenas prácticas en el desarrollo de proyectos tecnológicos.

A continuación, se presenta el enlace de acceso al repositorio (acceso directo):

https://github.com/carlosrgv1975/acif104_s6_grupo04_Arganaraz_Gonzalez

Repositorio público disponible para revisión académica.

De esta forma, se garantiza la transparencia del trabajo realizado y la posibilidad de replicar los resultados obtenidos.

IX. BIBLIOGRAFIA

Géron, A. (2022). Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

Kaggle. (2020). Healthcare Stroke Dataset. De <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>

Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques. Morgan Kaufmann.