

PREDICCIÓN DE ACCIDENTE CEREBROVASCULAR

Stroke Prediction Dataset - Análisis con Machine Learning

APRENDIZAJE DE MÁQUINAS (ACIF104)

Informe Fase 2 - Trabajo Evaluado (Mejora de acuerdo a observaciones)

Priscila Arganaraz | Carlos González

Grupo 04 - ACIF104 Aprendizaje de Maquinas

Ingeniería Civil Informática - Universidad Andrés Bello

Mayo 2026

GitHub: https://github.com/carlosrgv1975/acif104_s6_grupo04_Arganaraz_Gonzalez

INDICE

1. INTRODUCCIÓN Y OBJETIVOS	2
1.1 Objetivos Específicos	2
2. ANÁLISIS EXPLORATORIO DE DATOS (EDA)	3
2.1 Distribución de Variables Numéricas	3
2.2 Matriz de Correlación y Distribución por Clase	4
2.3 Variables Categóricas vs Stroke.....	4
3. COMPARACIÓN DE MODELOS DE MACHINE LEARNING	5
3.1 Resultados por Modelo.....	5
3.2 Reportes de Clasificación	5
4. TÉCNICAS DE BALANCEO DE CLASES.....	6
5. RED NEURONAL CON KERAS.....	7
5.1 Arquitectura	7
5.2 Configuración y Resultados.....	7
6. COMPARACIÓN FINAL DE TODOS LOS MODELOS.....	8
7. EXPLICABILIDAD DEL MODELO CON SHAP	9
7.1 Importancia Global de Variables.....	9
7.2 Impacto por Variable (Beeswarm)	10
7.3 Conclusiones de Explicabilidad	10
8. APLICACIÓN WEB — STREAMLIT	11
8.1 Características.....	11
8.2 Ejemplo de Predicción	11
9. CONCLUSIONES	12
9.1 Trabajo Futuro	12
10. REFERENCIAS	13

1. INTRODUCCIÓN Y OBJETIVOS

Este trabajo corresponde al proyecto final del curso ACIF104 Aprendizaje de Maquinas de la Universidad Andrés Bello. El objetivo principal es desarrollar un sistema de predicción de accidente cerebrovascular (stroke) utilizando técnicas de Machine Learning, con especial atención al manejo del desbalance de clases, la explicabilidad del modelo y el despliegue en una aplicación web interactiva.

El dataset utilizado contiene información clínica y demográfica de pacientes. La variable objetivo (stroke) presenta un severo desbalance: aproximadamente el 95% de los casos corresponden a la clase negativa (sin stroke) y solo el 5% a la clase positiva.

1.1 Objetivos Específicos

- Realizar un Análisis Exploratorio de Datos (EDA) completo con visualizaciones estadísticas
- Comparar al menos 3 algoritmos de Machine Learning clásicos
- Aplicar y comparar técnicas de balanceo de clases
- Implementar una Red Neuronal con Keras
- Generar explicaciones del modelo con SHAP
- Desplegar una aplicación interactiva con Streamlit para predicción en tiempo real

2. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

El EDA constituye el primer paso para comprender la estructura y distribución de los datos. Se analizaron variables numéricas (edad, glucosa, IMC) y variables categóricas (genero, estado de fumador, tipo de trabajo), evaluando su relación con la variable objetivo.

2.1 Distribución de Variables Numéricas

- Edad: distribución aproximadamente uniforme entre 0 y 80 años, con mayor concentración en la franja 40-80 donde se concentran los casos de stroke.
- Glucosa: distribución con sesgo positivo. Los niveles altos de glucosa (>150) están asociados a mayor riesgo de stroke.
- BMI: concentración central en valores entre 20 y 40, con outliers significativos por encima de 60.




Figura 1: Histogramas y boxplots de variables numéricas (Edad, Glucosa, BMI)

2.2 Matriz de Correlación y Distribución por Clase

La variable edad es la más correlacionada con stroke (0.25), seguida por avg_glucose_level (0.13) e hypertension (0.13). El grafico de distribución de edad por clase confirma que los casos de stroke se concentran en mayores de 40 años.




Figura 2: Matriz de correlación y distribución de edad por clase

2.3 Variables Categóricas vs Stroke

El desbalance de clases es consistente en todos los subgrupos. Las mujeres presentan ligeramente más casos de stroke en términos absolutos. En cuanto al habito de fumar, el grupo never smoked concentra más casos positivos, mediado por la edad.




Figura 3: Variables categóricas vs clase Stroke

3. COMPARACIÓN DE MODELOS DE MACHINE LEARNING

Se entrenaron y evaluaron tres modelos clásicos de Machine Learning, todos configurados con `class_weight='balanced'`. Las métricas principales fueron AUC-ROC y Recall de la clase positiva, dado que en el contexto medico los falsos negativos son más costosos.

3.1 Resultados por Modelo

Modelo	Recall (clase 1)	F1-Score	AUC-ROC	Observación
Random Forest	0.00	0.000	0.785	Sin detección de positivos
Regresión Logística	0.80	0.232	0.840	Mejor modelo seleccionado
XGBoost	0.12	0.129	0.764	Recall bajo
Red Neuronal (Keras)	0.80	0.223	0.821	AUC competitiva

El Random Forest fallo en detectar casos positivos (recall = 0.00). La Regresión Logística obtuvo el mejor balance (AUC: 0.840, recall: 0.80). XGBoost mostro desempeño inferior en ambas métricas.

3.2 Reportes de Clasificación

```

=== Random Forest ===
      precision    recall  f1-score   support

     0       0.95        1.00        0.97        972
     1       0.00        0.00        0.00         50

   accuracy          0.95        1022
  macro avg       0.48        0.50        0.49        1022
 weighted avg       0.90        0.95        0.93        1022

AUC-ROC: 0.785

=== Regresión Logística ===
      precision    recall  f1-score   support

     0       0.99        0.74        0.84        972
     1       0.14        0.80        0.23         50

   accuracy          0.74        1022
  macro avg       0.56        0.77        0.54        1022
 weighted avg       0.94        0.74        0.81        1022

AUC-ROC: 0.840
...
      recall    f1    auc
Random Forest    0.00  0.000  0.785
Regresión Logística    0.80  0.232  0.840
XGBoost           0.12  0.129  0.764
  
```

Figura 4: Reportes de clasificación — Random Forest y Regresión Logística

4. TÉCNICAS DE BALANCEO DE CLASES

El desbalance severo (95% vs 5%) fue abordado mediante tres estrategias diferentes, evaluadas sobre el mismo conjunto de prueba para garantizar comparabilidad.

- `class_weight='balanced'`: ajusta internamente los pesos de las clases durante el entrenamiento.
- SMOTE: genera ejemplos sintéticos de la clase minoritaria interpolando entre instancias existentes.
- Undersampling aleatorio: reduce la clase mayoritaria eliminando instancias aleatoriamente.

Técnica	Recall	F1	AUC	Comentario
<code>class_weight (balanced)</code>	0.80	0.232	0.840	Referencia base
SMOTE (sobremuestreo)	0.80	0.231	0.841	Similar a base
Undersampling	0.82	0.214	0.835	Recall levemente mayor

Las tres técnicas produjeron resultados similares. Se seleccionó `class_weight` como técnica base por su simplicidad y robustez.

```

=== COMPARACION DE TECNICAS DE BALANCEO ===

=== Sin balanceo (class_weight) ===
      precision    recall  f1-score   support

     0       0.99      0.74      0.84       972
     1       0.14      0.80      0.23        50

   accuracy          0.74       1022
  macro avg       0.56      0.77      0.54       1022
 weighted avg       0.94      0.74      0.81       1022

=== SMOTE (sobremuestreo) ===
      precision    recall  f1-score   support

     0       0.99      0.74      0.84       972
     1       0.14      0.80      0.23        50

   accuracy          0.74       1022
  macro avg       0.56      0.77      0.54       1022
 weighted avg       0.94      0.74      0.81       1022

=== Undersampling ===
      precision    recall  f1-score   support
...
              recall    f1    auc
Sin balanceo (class_weight)    0.80 0.232 0.840
SMOTE (sobremuestreo)          0.80 0.231 0.841
Undersampling                  0.82 0.214 0.835

```

Figura 5: Comparación de técnicas de balanceo de clases

5. RED NEURONAL CON KERAS

5.1 Arquitectura

- Dense(64, relu) + Dropout(0.3)
- Dense(32, relu) + Dropout(0.3)
- Dense(16, relu)
- Dense(1, sigmoid) — salida binaria

Total parámetros entrenables: 3,649 (14.25 KB).

```

Pesos de clase: {0: 0.5255915637860082, 1: 10.268844221105528}
Model: "sequential"
  
```

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 64)	1024
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 32)	2080
dropout_1 (Dropout)	(None, 32)	0
dense_2 (Dense)	(None, 16)	528
dense_3 (Dense)	(None, 1)	17

```

=====
Total params: 3649 (14.25 KB)
Trainable params: 3649 (14.25 KB)
Non-trainable params: 0 (0.00 Byte)
  
```

32/32 [=====]	- 0s 5ms/step
32/32 [=====]	- 0s 6ms/step
...	
macro avg	0.56 0.76 0.53 1022
weighted avg	0.94 0.73 0.80 1022

Figura 6: Arquitectura de la red neuronal (Keras summary)

5.2 Configuración y Resultados

- Función de pérdida: binary_crossentropy
- Optimizador: Adam con pesos de clase {0: 0.526, 1: 10.268}
- AUC-ROC obtenido: 0.821 | Recall clase positiva: 0.80

La red neuronal obtuvo resultados competitivos aunque ligeramente inferiores a la Regresión Logística, lo que sugiere que para datasets de tamaño moderado los modelos lineales pueden ser igualmente efectivos.



6. COMPARACIÓN FINAL DE TODOS LOS MODELOS

```

=== COMPARACION FINAL DE TODOS LOS MODELOS ===

```

	recall	f1	auc
Random Forest	0.00	0.000	0.785
Regresion Logistica	0.80	0.232	0.840
XGBoost	0.12	0.129	0.764
Red Neuronal (Keras)	0.80	0.223	0.821

Modelo seleccionado: Regresión Logística con class_weight='balanced'

Justificación: Mayor AUC (0.840) y mejor recall (0.80) para detectar casos de stroke

Figura 7: Tabla comparativa final — Recall, F1 y AUC-ROC de todos los modelos




Figura 8: Grafico comparativo de métricas clave por modelo

Modelo seleccionado: Regresión Logística con class_weight='balanced' (AUC: 0.840, Recall: 0.80). Justificación: mayor capacidad discriminativa, mejor detección de casos positivos, alta interpretabilidad y eficiencia computacional.

7. EXPLICABILIDAD DEL MODELO CON SHAP

Se aplicó SHAP (SHapley Additive exPlanations) para garantizar la transparencia del modelo, asignando a cada variable una contribución marginal promedio a la predicción.

7.1 Importancia Global de Variables




Figura 9: Importancia global de variables según SHAP (mean |SHAP value|)

La variable edad domina ampliamente la predicción (SHAP ~1.6), casi diez veces superior a la segunda variable (work_type_children ~0.18), confirmando que la edad es el factor de riesgo dominante.

7.2 Impacto por Variable (Beeswarm)




Figura 10: Análisis SHAP — impacto por variable y valor de feature

Para la edad: valores altos generan valores SHAP positivos elevados, indicando que mayor edad aumenta significativamente el riesgo. Para glucosa: valores altos también incrementan el riesgo. La hipertensión eleva consistentemente el riesgo predicho.

7.3 Conclusiones de Explicabilidad

- Edad: variable dominante con impacto no lineal creciente sobre el riesgo
- Nivel de glucosa: segundo factor más influyente en valores elevados
- Hipertensión: factor cardiovascular relevante confirmado por SHAP
- BMI: impacto moderado, consistente con literatura medica

8. APLICACIÓN WEB — STREAMLIT

Se desarrolló una aplicación web interactiva con Streamlit que permite realizar predicciones de riesgo de stroke en tiempo real, ingresando datos clínicos del paciente mediante una interfaz intuitiva.

8.1 Características

- Interfaz: panel lateral con sliders y dropdowns para ingresar datos del paciente
- Variables de entrada: edad, hipertensión, enfermedad cardiaca, glucosa, BMI, genero, estado civil, habito de fumar, tipo de trabajo, tipo de residencia
- Backend: Regresion Logistica con `class_weight='balanced'` (AUC-ROC: 0.840)
- Resultados: probabilidad de stroke (%), clasificación de riesgo y variables importantes según SHAP
- URL local: <http://127.0.0.1:8501>
-




Figura 11: Captura de pantalla de la aplicación Streamlit

8.2 Ejemplo de Predicción

Paciente ejemplo: 50 años, hipertensión Si, sin enfermedad cardiaca, glucosa 100, BMI 28, género femenino, no casada, nunca fumo, trabajo privado, residencia urbana. Resultado: BAJO RIESGO, probabilidad de stroke 41.8%.

9. CONCLUSIONES

- El desbalance de clases (95%/5%) fue el principal desafío técnico. Las tres técnicas evaluadas produjeron resultados similares, con leve ventaja de SMOTE en AUC.
- La Regresión Logística supero a Random Forest y XGBoost en las métricas más relevantes para el contexto medico (AUC-ROC y recall de la clase positiva).
- La red neuronal (Keras) obtuvo resultados competitivos (AUC: 0.821, recall: 0.80) pero no supero al modelo lineal.
- El análisis SHAP confirmo que la edad es el predictor dominante, seguido por glucosa e hipertensión, en acuerdo con la evidencia clínica.
- La aplicación Streamlit demuestra la viabilidad de desplegar el modelo para uso práctico.

9.1 Trabajo Futuro

- Explorar modelos de ensemble más avanzados (LightGBM, CatBoost)
- Implementar validación cruzada estratificada con k=10
- Despliegue en la nube (AWS, Heroku) para acceso publico
- Incorporar curvas ROC y matrices de confusión interactivas en la app

10. REFERENCIAS

- Fedesoriano (2021). Stroke Prediction Dataset. Kaggle. <https://www.kaggle.com/fedesoriano/stroke-prediction-dataset>
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.
- Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD 2016.
- Lundberg, S. M. & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS 2017.
- Chawla, N. V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. JAIR, 16, 321-357.
- Chollet, F. et al. (2015). Keras. <https://keras.io>
- Streamlit Inc. (2023). Streamlit — The fastest way to build data apps. <https://streamlit.io>